机器学习总结

监督学习

BP神经网络

基本原理是通过前向传播和反向传播两个阶段来调整权重，
从而减少预测误差，
使网络能够学习输入和输出之间的复杂映射关系。

- 前向传播过程
  - 前向传播是BP神经网络的第一步，其过程是将输入数据通过各层神经元进行处理，最终输出预测结果。
  - 在这个过程中，每个神经元会进行加权求和，并通过激活函数生成输出。
  - 这一过程使得网络可以逐渐学习到输入特征与目标结果之间的关系
- 反向传播算法
  - 反向传播是BP神经网络的核心算法，主要用于优化权重。
  - 通过计算输出误差相对于每一层权重的导数，
  - 并利用链式法则将误差反向传递，从而调整网络中的所有权重。
  - 这个过程是一个迭代的优化过程，通常使用梯度下降法来最小化损失函数，以提高模型的准确性

感知机

单层感知机（Single Layer Perceptron）是最简单的人工神经网络，它
由一个输入层和一个输出层组成，输入层负责接收特征，输出层负责产生预测值。
该模型只能处理线性可分的数据，即样本可以用一条直线或超平面分隔开

多层感知机（Multilayer Perceptron, MLP）则是由多个神经元层组成的前馈神经网络，至少包含一个隐藏层和一个输出层。隐藏层通过非线性激活函数（如ReLU、sigmoid等）实现复杂的变换，从而能够处理非线性可分的任务

卷积神经网络

卷积神经网络（Convolutional Neural Network, CNN）是一种深度学习模型，
特别适用于图像处理和计算机视觉任务。

- 输入层：接受输入数据
- 卷积层：负责特征提取，通过卷积操作提取局部特征
- 池化层：通过下采样降低特征维度以减少计算量，并增强模型的平移不变性
- 全连接层：将提取到的特征映射转换为最终的分类结果
- 经典的网络结构
  - LENET-5
  - VGG系列模型
  - ResNet

循环神经网络

循环神经网络（Recurrent Neural Network, RNN）是一种适用于处理序列数据的深度学习模型。
与传统的前馈神经网络不同，RNN具备记忆功能，
能够处理输入数据之间的时间关系，并有效捕捉序列中的依赖性

- 简单循环神经网络
  - 简单循环神经网络(simple recurrent network, SRN)顾名思义，
    是一种最简单的循环神经网络，
    它只有一个隐藏层，这个隐藏层也称为简单循环层。
  - 特点：将输入数据乘以对应的权重，加上偏置，
    交由神经元使用激活函数激活输出，还将接收和处理上一时间步的输出
- 长短期记忆神经网络
  - （long short-term memory, LSTM）是循环神经网络中较常用的一种网络，
    它具有长期记忆能力，
    可以有效地解决简单循环神经网络梯度消失或梯度爆炸问题
  - 遗忘门：决定需要遗忘记忆单元状态的哪些数据，保留哪些数据
  - 输入门：决定需要更新记忆单元状态的哪些数据，包括新增数据和需要替换的数据
  - 输出门：决定记忆单元状态中有哪些数据输出至下一记忆单元，作为其输入数据
- 门控循环单元神经网络
  - （gated recurrent unit, GRU）长短期记忆神经网络的变体，
    简化了长短期记忆神经网络的计算流程，减少了门控的数量
  - 重置门：用于控制保留多少之前的数据
  - 更新门：用于控制数据的保留与更新
  - Tanh神经层：产生最后需要输出的候选数据

迁移学习方法

迁移学习（transfer learning）是一种机器学习技术，
它通过从相关领域已学习的任务中转移知识，完成或改进目标域的任务学习效果。

- 分类
  - 按学习方式分类
    - 基于样本的迁移学习
    - 基于特征的迁移学习
    - 基于模型的迁移学习
    - 基于关系的迁移学习
  - 按迁移场景分类
    - 归纳式迁移学习
    - 直推式迁移学习
    - 无监督迁移学习
  - 按特征空间分类
    - 同构迁移学习
    - 异构迁移学习

预训练模型

预训练模型是指一些已经在大型数据集上经过长期训练得到的模型。
通常这些预训练模型具有良好的模型权重参数。
因此，在一些新模型进行迁移学习时，它们常被作为基础底层模型用于训练。

- 预训练模型的复用方式
  - 训练整个模型
  - 训练一些层，冻结其他层
  - 冻结卷积基

对抗神经网络

生成对抗神经网络（generative adversarial networks, GAN）
是一种基于博弈论的深度学习神经网络模型，
它通过一个相互对抗的过程来完成模型的训练

- 生成模型（generative model, 简称G）
  - 生成模型尝试生成与真实样本分布一致的样本，
    目的是欺骗判别模型，
    让判别模型认为生成样本是真实的
- 判别模型（discriminative model, 简称D）
  - 判别模型试图将生成样本与
    原始训练集的真实样本区分开。

机器学习应用流程

- 数据集准备：在机器学习中，数据集是构建模型的基础。数据集通常以M×N 的矩阵形式表现，其中M代表特征（列），N 代表样本（行）
- 数据预处理：数据预处理是机器学习流程中至关重要的一步，涉及到数据的清理、整理和规范化。预处理步骤可以包括:
  缺失值处理: 补充缺失的数据或删除含缺失值的样本。
  数据转换: 使数据按特定标准化或者正态化。
  特征选择: 从原始数据中选取重要的特征，排除无关特征
- 探索性数据分析：在这一阶段，通过描述性统计和可视化分析方法，深入了解数据的特性与结构。常见方法包括:
  统计分析: 计算均值、中位数和标准差等指标。
  可视化工具: 使用热力图、箱形图和散点图等方法展示数据分布
- 数据分割：为使模型具有良好的泛化能力，通常会将数据集分割为训练集、验证集和测试集。具体分割方法包括:
  训练集: 用于模型的训练（如占80%）。
  验证集: 用于调参和模型选择。
  测试集: 用于评估模型在未见数据上的性能。
- 选择机器学习算法：选择合适的机器学习算法是模型构建的重要环节。算法的选择依据任务类型（分类、回归等）和数据特性而定。常见算法包括线性回归、决策树、支持向量机和深度学习模型等
- 模型训练：利用训练集进行模型的训练。在这一过程中，可以使用不同的策略，调整模型的参数并进行超参数优化。通过迭代过程，使模型在训练集上达到良好的拟合效果
- 模型评估：通过模型在测试集上的表现来评估其性能。常用的评估指标包括准确率、精确率、召回率和F1分数等。评估结果可以指导后续的模型调优。
- 模型部署：在模型训练和评估后，最终模型可以进行部署，应用于实际场景中。此步骤包括将模型整合进现有系统，确保其能够实时处理输入数据

降低维度算法

- 主成份分析（Principle Component Analysis， PCA）
- 偏最小二乘回归（Partial Least Square Regression，PLS）
- Sammon映射
- 多维尺度（Multi-Dimensional Scaling, MDS）
- 投影追踪（Projection Pursuit）

正则化算法

- Ridge Regression
- Least Absolute Shrinkage and Selection Operator（LASSO）
- 以及弹性网络（Elastic Net）

机器学习的应用领域

- 医疗健康
- 金融行业
- 图像与视觉识别
- 自然语言处理
- 电子商务与市场营销

无监督方法

聚类算法

- k-Means算法
- 期望最大化算法（Expectation Maximization， EM）

关联规则算法

- Apriori算法
- Eclat算法

回归算法

- 逻辑回归（Logistic Regression）
  - 核心思想是使用一个Sigmoid函数将线性回归模型的输出映射到0和1之间，从而表示一个二元事件发生的概率
  - 通常使用梯度下降（Gradient Descent）算法来优化损失函数
- 线性回归（linear regression）
  - 核心思想是找到一条直线（在二维空间中）或一个超平面（在多维空间中），这条直线或超平面能够最好地拟合输入变量（特征）与输出变量（目标）之间的关系
  - 通常使用均方误差（Mean Squared Error, MSE）作为损失函数

贝叶斯方法

- 核心思想是使用贝叶斯定理来计算条件概率，特别是在给定证据的情况下对假设的概率进行更新
- 全概率是概率论中的一个重要公式，它用于计算在某一事件发生的条件下，另一个事件发生的概率，当这个条件事件是由多个互斥且完备的事件组成时
- 先验概率是根据以往经验和分析得到的概率。我们用P(A)来代表在没有训练数据前假设A拥有的初始概率
- 后验概率根据已经发生的事件来分析得到的概率。以P(B|A)代表假设A成立的情下观察到Y数据的概率，因为它反映了在看到训练数据A后B成立的置信度
- 联合概率是指在多元的概率分布中多个随机变量分别满足各自条件的概率。A与B的联合概率表示为P(A,B)、P(AB) 或P(A∩B)

$$P(A|B) = \frac{P(B,A)}{P(B)} = \frac{P(B|A)P(A)}{P(B)}$$

（后验概率 / 似然度 / 先验概率 / 边际似然度）

贝叶斯公式

KNN算法

- 核心思想是基于距离度量，即某个点与其同类点的距离最近，因此可以通过邻近点的标签来预测该点的标签。
- 距离度量
  - $d(x,y) = \sqrt{\sum_i (x_i - y_i)^2}$ 欧氏距离
  - $d(x,y) = \sum_i |x_i - y_i|$ 曼哈顿距离
  - $d(x,y) = \max_i |x_i - y_i|$ 切比雪夫距离
  - $d(x,y) = \left(\sum_i |x_i - y_i|^p\right)^{\frac{1}{p}}$ 闵可夫斯基距离
- 三要素
  - k值选择
  - 距离度量
  - 决策规则
    - 分类问题：在K个最近邻中，根据多数表决的原则，即得票最多的类别将是预测类别
    - 回归问题：计算K个最近邻的目标值的平均值，作为新实例的预测值。

决策树

- 信息熵是衡量数据集不确定性或随机性的一个指标
- 信息增益是衡量一个特征对于数据集分类能力提升的指标
- ID3 —— 核心思想是使用信息论的概念来评估特征的重要性。它通过计算数据集的信息熵和特征条件熵来确定每个特征的**信息增益**，并选择信息增益最大的特征进行分割
- C4.5 —— 核心思想仍然是使用**信息增益比**来选择最佳分割属性，并通过递归地构建决策树来对数据进行分类
- CART —— 核心思想是使用二叉树模型来表示决策过程，每个内部节点代表一个特征上的测试，每个分支代表测试的结果，每个叶节点代表决策的输出

集成学习

- Bagging
  - 核心思想结合多个模型的预测结果来提高整体预测的准确性和稳定性
  - RF
    - Bagging 的扩展
    - 心思想是“集思广益”，即通过组合多个决策树的预测结果来获得比单棵决策树更可靠的预测
- Boosting —— 核心思想将多个弱学习器集合在一起形成一个强学习器
- Stacking —— 核心思想是训练多个不同的基模型，并将它们的预测结果作为新模型的输入特征，以此来得到最终的预测结果
- AdaBoost —— 核心在于迭代地训练一系列弱分类器，并且每个分类器都更关注前一个分类器错误分类的样本。每个弱分类器对最终的分类结果都有贡献，其贡献度（权重）取决于其分类性能
- GBDT —— 核心思想是将多个弱学习器（决策树）组合成一个强学习器。每一棵新树都尝试纠正前一棵树的错误，这个过程是迭代进行的，直到达到预定的树的数量或满足其他停止条件。
- XGBoost
  - 核心思想是将多个弱预测模型（通常是决策树）组合成一个强预测模型。通过迭代地添加新的树模型来纠正前一个模型的预测误差，从而逐步提升模型的性能。
  - 针对大规模数据集进行了优化
  - 支持并行处理，可以并行构建树，这使得XGBoost在处理大规模数据集时更加高效
- LightGBM —— 核心思想是实现一个更高效的梯度提升框架，通过一系列优化措施减少计算和内存开销，同时保持或提高模型的准确性。

支持向量机（SVM）

- 核心思想是找到一个超平面，使得不同类别的数据点之间的间隔（边缘）最大化。这个间隔定义为最近邻数据点到超平面的距离。SVM通过引入拉格朗日乘子法和KKT条件来求解最优化问题
- 线性可分支持向量机
  - 对于线性可分的情况，SVM可以直接找到最优的超平面。这种情况下，存在一个超平面能够完美地分隔不同类别的数据点
  - 强调数据集是完美的线性可分性
- 线性支持向量机
  - 线性支持向量机（Linear SVM）是支持向量机（SVM）的一个特例，它适用于线性可分的数据集。在这种情况下，数据集可以通过一个超平面（在二维空间中是一条直线，在三维空间中是一个平面）清晰地分隔成两个类别
  - 处理非线性可分数据时，线性SVM可以通过引入软间隔和松弛变量来适应数据
- 线性不可分支持向量机
  - 数据集中的样本存在重叠，无法找到一个单一的超平面将它们完美分
  - 核技巧
    - 核函数，可以将样本从原始空间映射到一个更高维的特质空间中，使得样本在新的空间中线性可分
    - 线性核函数
      - 计算两个输入向量的点积
      - 计算速度快，不具备处理非线性关系的能力
    - 多项式核函数
      - 可以将输入向量映射到更高维的空间
      - 处理非线性关系，通过调整参数可以模拟不同的非线性边界。计算复杂。
    - 高斯核函数
      - 也称为径向基函数核，用于模拟数据点之间的相似度
      - 处理非线性问题，不容易过拟合