

实验三 回归分析

（一）目的和要求

- （1）掌握回归分析的概念的使用场景
- （2）掌握机器学习回归分析的进行数据预测的有效方法。
- （3）掌握特征重要性分析，特征选择和模型优化的方法。

（二）实验知识准备

- （1）数据准备：收集相关数据，确保数据的质量和完整性。进行必要的数据清洗和预处理，包括处理缺失值、异常值和数据类型转换。
- （2）特征选择：选择与目标变量相关的特征，并考虑特征之间的相互作用。创建新特征以增强模型的表现，如多项式特征、交互特征等。
- （3）模型选择：根据数据的特性选择合适的回归模型，如线性回归、决策树回归、随机森林回归等。考虑模型的复杂性与可解释性之间的平衡。
- （4）模型训练与验证：使用训练集对模型进行训练，并通过交叉验证等方法评估模型的泛化能力。选择合适的评价指标，如均方误差(MSE)、平均绝对误差(MAE)等，来评估模型的性能。
- （5）结果解释与可视化：解释模型的输出结果，尤其是特征的重要性。使用可视化工具展示预测结果与真实值之间的关系，以便更直观地理解模型的表现。
- （6）模型优化：通过调整超参数、特征选择等方法提高模型的性能。评估模型在新数据上的表现，确保其稳定性和可靠性。

（三）实验内容及步骤

（1）使用线性回归预测波士顿房价

使用线性回归模型对波士顿房价数据集进行分析与预测。通过加载数据、分割训练集与测试集并训练线性回归模型，计算均方误差（MSE）和 R^2 值以评估模型性能。可视化结果通过散点图展示了真实房价与预测房价的关系，同时通过残差图分析了模型的误差分布。

1. 步骤一，导入本项目所需要的模块和包，如图 1 所示。

```

1 import pandas as pd
2 import numpy as np
3 import matplotlib.pyplot as plt
4 import seaborn as sns
5 import tensorflow as tf
6 from sklearn.model_selection import train_test_split
7 from sklearn.linear_model import LinearRegression
8 from sklearn.metrics import mean_squared_error, r2_score

```

图 1 导入所需模块

2. 步骤二，使用 `load_data()`函数从 TensorFlow 的 Keras 库中导入波士顿房价数据集到本地计算机中。参考代码如图 2 所示。

```

1 (x_train, y_train), (x_test, y_test) =
  tf.keras.datasets.boston_housing.load_data(test_split=0.3)
2 # 查看数据形状
3 print("训练集样本数:", x_train.shape[0])
4 print("测试集样本数:", x_test.shape[0])

```

图 2 从 Keras 加载数据集

3. 步骤三，建立并训练模型，如图 3 所示。

```

1 model = LinearRegression()
2 model.fit(x_train, y_train)

```

图 3 建立并训练模型

4. 步骤四，进行预测并评估模型，示例代码如图 4 所示。

```

1 y_pred = model.predict(x_test)
2 mse = mean_squared_error(y_test, y_pred)
3 r2 = r2_score(y_test, y_pred)
4 print(f'Mean Squared Error: {mse:.2f}')
5 print(f'R2 Score: {r2:.2f}')

```

图 4 进行预测和评估

模型的 R^2 值和均方误差为评估模型依据。

5. 步骤五，可视化真实值预预测值，示例代码如图 5。

```

1 # 设置全局字体
2 plt.rcParams['font.sans-serif'] = ['SimHei'] # 黑体
3 plt.rcParams['axes.unicode_minus'] = False # 正常显示负号
4 plt.figure(figsize=(10, 6))
5 plt.scatter(y_test, y_pred, alpha=0.7)
6 plt.plot([min(y_test), max(y_test)], [min(y_test), max(y_test)],
    color='red', linewidth=2)
7 plt.xlabel('真实房价')
8 plt.ylabel('预测房价')
9 plt.title('真实房价 vs 预测房价')
10 plt.grid()
11 plt.show()

```

图 5 可视化真实值预测值

使用散点图对真实值和预测值的分布情况进行可视化，如图 6 所示。




图 6 预测值与真实值分布

从图 6 可以看出散点大多集中在对角线附近，说明模型性能良好，预测值与真实值接近。

6. 步骤六，进行残差分析，示例代码如图 7 所示。

```

1 residuals = y_test - y_pred
2 plt.figure(figsize=(10, 6))
3 sns.histplot(residuals, bins=30, kde=True)
4 plt.title('残差分布')
5 plt.xlabel('残差')
6 plt.ylabel('频数')
7 plt.axvline(0, color='red', linestyle='--')
8 plt.show()

```

图 7 进行残差分析

使用柱状图可视化残差分析结果，效果如图 8 所示。




图 8 可视化残差分析

从图 8 可以看出，残差分布接近正态分布，表明模型适合数据。

说明：残差分布接近正态分布表明线性回归模型适合数据，因为这意味着模型的预测误差是均匀的，没有系统性偏差，反映了模型能够有效捕捉目标变量的影响因素。正态分布的残差还支持统计推断的有效性，使得参数估计和置信区间更加可靠。如果残差明显偏离正态分布，则可能表明模型未能充分捕捉数据中的结构，需考虑调整模型或特征。

7. 步骤七，进行特征相关性分析，示例代码如图 9 所示。

```

1 # 将训练集数据转换为 DataFrame，确保列名与特征数匹配
2 train_data = pd.DataFrame(x_train, columns=[
3     'CRIM', 'ZN', 'INDUS', 'CHAS', 'NOX', 'RM', 'AGE', 'DIS',
4     'RAD', 'TAX', 'PTRATIO', 'B', 'LSTAT'
5 ])
6 # 添加目标变量
7 train_data['MEDV'] = y_train # 目标变量
8 # 计算相关性矩阵
9 correlation_matrix = train_data.corr()
10 # 提取与目标变量的相关性并排序
11 correlation_with_target = correlation_matrix['MEDV'].drop('MEDV') # 去掉目标变量本身
12 sorted_features =
    correlation_with_target.abs().sort_values(ascending=False).index # 按绝对值排序
13 # 根据排序后的特征重新排列相关性矩阵
14 sorted_correlation_matrix = correlation_matrix.loc[sorted_features,
    sorted_features]
15 # 绘制热图
16 plt.figure(figsize=(12, 10))
17 sns.heatmap(sorted_correlation_matrix, annot=True, cmap='coolwarm',
    fmt='.2f', linewidths=0.5)
18 plt.title('特征相关性热图')
19 plt.show()

```

图 9 特征相关性分析

使用热图来展示特征间的相关性，效果如图 10 所示。




图 10 特征相关性热图

特征相关性热图是一种可视化工具，用于展示不同特征之间的相关性。通过热图可以直观地看到特征之间的相互关系，通常使用颜色深浅（通常是颜色渐变）来表示相关性强弱。以下是如何解读特征相关性热图的几个关键点：

a. **相关性系数**，相关性系数范围：1：完全正相关（当一个特征增加时，另一个特征也增加）。-1：完全负相关（当一个特征增加时，另一个特征减少）。0：无相关性（两个特征之间没有线性关系）。

b. **颜色**，深色（如深蓝或深红）通常表示强相关性，深色越深，相关性越强。浅色（如浅蓝或浅红）表示弱相关性。

c. **特征之间的关系**，高度相关的特征：如果两个特征之间的相关性系数接近于 1 或 -1，表明它们之间具有较强的线性关系。这可能导致多重共线性问题，因此在建模时需要谨慎处理。低相关的特征：如果两个特征的相关性系数接近于 0，则说明它们之间几乎没有线性关系，这可能意味着它们可以独立地提供信息。

8. 步骤八，进行特征重要性分析并进行可视化，示例代码如图 11 所示。特征重要性排序的结果可以帮助理解每个特征对模型预测的影响。

d. **系数**，在回归模型中，每个特征的系数表示该特征对目标变量的影响程度：正系数：表示特征的值增加时，目标变量的值也会增加。例如，如果 RM（平均房间数）的系数为正，说明房间数增加会导致房价中位数上升。负系数：表示特征的值增加时，目标变量的值会减少。例如，如果 CRIM（犯罪率）的系数为负，说明犯罪率增加会导致房价中位数下降。

e. **绝对值的大小**，绝对值较大的系数：说明该特征对目标变量的影响较大。比如，如果 RM 的系数为 4.5，而 LSTAT（低收入人口比例）的系数为 -2.0，说明 RM 对房价的影响比 LSTAT 更显著。绝对值较小的系数：表示该特征对目标变量的影响较小，可能在模型中不太重要。

f. **特征排序**，通过排序后的结果可以快速识别出最重要的特征。如发现 RM 和 LSTAT 是影响房价中位数的两个最重要特征。

g. **特征重要性排序还提供了模型的解释性**。通过了解哪些特征在模型中起到关键作用。

h. **特征处理**，根据特征重要性排序的结果，可以执行保留重要特征，删除不

重要特征或增强重要特征等操作。

```
1 # 计算特征重要性
2 coefficients = model.coef_
3 # 创建一个 DataFrame 来显示特征名称及其对应的系数
4 feature_importance = pd.DataFrame({
5     'Feature': train_data.columns[:-1], # 排除目标变量
6     'Coefficient': coefficients
7 })
8
9 # 按系数绝对值进行排序
10 feature_importance['Absolute Coefficient'] =
    feature_importance['Coefficient'].abs()
11 sorted_features = feature_importance.sort_values(by='Absolute
    Coefficient', ascending=False)
12
13 # 输出排序结果
14 print("特征重要性排序: ")
15 print(sorted_features[['Feature', 'Coefficient']])
16
17 # 可视化特征重要性
18 plt.figure(figsize=(12, 6))
19 # 设置 hue 为特征, 并禁用图例
20 sns.barplot(x='Coefficient', y='Feature', data=sorted_features,
    palette='viridis', hue='Feature', legend=False)
21 plt.title('特征重要性排序')
22 plt.xlabel('系数值')
23 plt.ylabel('特征')
24 plt.grid()
25 plt.show()
```

图 11 特征重要性分析

实验使用条形图来展示特征的重要性, 效果如图 12 所示。




图 12 特征重要性条形图

从图 12 可以看出, 有以下几个重要的特征:

a. 正面影响特征特征

NOX: 对房价的负面影响最大, 表明环境污染对房价的显著影响。

CHAS 和 RM: 这两个特征对房价的正面影响较大, 显示出良好的地理位置

和房间数的重要性。

b. 负面影响特征

DIS、PTRATIO、LSTAT 和 CRIM 等特征显示出对房价的负面影响，表明这些社会经济因素在房价中起到重要作用。

c. 微小影响特征

AGE、INDUS、TAX 和 B 的影响相对较小，可能在实际应用中不太重要，但仍需根据具体情况考虑。

具体分析见表 1。

表 1 特征及其系数说明

特征	系数	说明
NOX	-18.16	NOX 代表一氧化氮浓度，系数为负，表明 NOX 增加时，房价中位数显著下降。每增加一个单位的 NOX，房价中位数下降约 18.16。
CHAS	3.86	CHAS 是一个指示变量，表示是否靠近河流。系数为正，表明靠近河流的房产价格较高，增加约 3.86。
RM	3.40	RM 代表平均房间数，系数为正，说明房间数增加时，房价中位数上升。每增加一个房间，房价中位数增加约 3.40。
DIS	-1.55	DIS 是与就业中心的距离，系数为负，说明距离就业中心越远，房价中位数越低。每增加一个单位的距离，房价中位数下降约 1.55。
PTRATIO	-0.89	PTRATIO 是师生比例，系数为负，说明师生比例增加时，房价中位数下降。每增加一个单位，房价中位数下降约 0.89。
LSTAT	-0.62	LSTAT 代表低收入人口比例，系数为负，表明低收入人口比例增加时，房价中位数下降。每增加一个单位，房价中位数下降约 0.62。
RAD	0.33	RAD 是高速公路可达性指数，系数为正，表明可达性越好，房价中位数越高。每增加一个单位，房价中位数增加约 0.33。
CRIM	-0.13	CRIM 代表犯罪率，系数为负，说明犯罪率增加时，房价中位数下降。每增加一个单位，房价中位数下降约 0.13。
ZN	0.06	ZN 代表住宅用地比例，系数为正，表明住宅用地比例增加时，房价中位数略微上升。每增加一个单位，房价中位数增加约 0.06。
AGE	0.02	AGE 代表房屋年龄，系数为正，说明房屋年龄对房价的影响非常微小。每增加一个单位，房价中位数增加约 0.02。
INDUS	0.01	INDUS 代表工业用地比例，系数为正，说明其对房价的影响微乎

特征	系数	说明
		其微。
TAX	-0.01	TAX 是财产税率，系数为负，说明税率增加时，房价中位数略微下降，影响极小。
B	0.01	B 代表黑人比例，系数为正，表明其对房价的影响非常小。

(2) 实训项目

导入 `scikit-learn` 库中的鸢尾花数据集，使用回归分析对鸢尾花数据进行分类。
鸢尾花数据集各列说明如表 2 所示。

表 2 鸢尾花数据集说明

字段名称	字段类型	字段说明
SepalLength	浮点型	萼片长度（厘米）
SepalWidth	浮点型	萼片宽度（厘米）
PetalLength	浮点型	花瓣长度（厘米）
PetalWidth	浮点型	花瓣宽度（厘米）
Class	字符型	类别：Setosa, Versicolour, Virginica

表 2 表明鸢尾花数据集中共有 150 条数据，分为 3 类，每类 50 条数据，每条数据包含 4 个特征值和 1 个标签值，其中特征值分别是花萼长度、花萼宽度、花瓣长度和花瓣宽度，标签值表示鸢尾花的种类，分别是 Setosa、Versicolor 和 Virginica，用整数 0、1 和 2 表示

1. 步骤一，导入需要的库文件，并使用 `load_iris()` 函数导入 `scikit-learn` 库中的鸢尾花数据集。
2. 步骤二，对数据进行初步探索，包括查看数据的基本信息和可视化特征之间的关系。
3. 步骤三，将数据集分为训练集和测试集，通常按 8:2 或 7:3 的比例划分。
4. 步骤四，使用训练集训练逻辑回归模型。
5. 步骤五，使用测试集进行预测，并将结果保存下来。
6. 步骤六，使用混淆矩阵和分类报告来评估模型的性能。
7. 步骤七，选择两个特征进行可视化决策边界。